



Universidade do Minho
Escola de Ciências

Licenciatura em Estatística Aplicada

Laboratórios de Estatística II

Distribuição Gama e Análise NHANES

Autores: a101165, Joana Raquel Azevedo
a113231, Luís Filipe Gonçalves

Guimarães, Abril de 2026

Resumo

Este trabalho desenvolve-se em duas partes complementares no âmbito da unidade curricular de Laboratórios de Estatística II. Na primeira parte estuda-se a distribuição Gama, abordando a sua definição, parâmetros, medidas teóricas, probabilidades selecionadas e representações gráficas, com simulações ilustrativas da Lei dos Grandes Números e do Teorema do Limite Central. Na segunda parte realiza-se uma análise exploratória centrada no Índice de Massa Corporal da base de dados NHANES, recorrendo a medidas descritivas, gráficos comparativos e à construção de um intervalo de confiança para a média.

O trabalho inclui ainda uma aplicação interativa em *Streamlit* que complementa a análise desenvolvida, permitindo explorar os conteúdos de forma simples e intuitiva.

Palavras-chave: distribuição Gama, NHANES, BMI, Lei dos Grandes Números, Teorema do Limite Central, intervalo de confiança, Streamlit.

Abstract

This work is developed in two complementary parts within the course of Statistical Laboratories II. The first part studies the Gamma distribution, covering its definition, parameters, theoretical measures, selected probabilities and graphical representations, with illustrative simulations of the Law of Large Numbers and the Central Limit Theorem. The second part carries out an exploratory analysis focused on the Body Mass Index from the NHANES dataset, using descriptive measures, comparative graphs, and the construction of a confidence interval for the mean.

The project also includes an interactive *Streamlit* application that complements the developed analysis, allowing users to explore the content in a simple and intuitive way.

Keywords: Gamma distribution, NHANES, BMI, Law of Large Numbers, Central Limit Theorem, confidence interval, Streamlit.

Conteúdo

Resumo	i
Abstract	ii
Índice de figuras	iv
Índice de tabelas	v
1 Introdução	1
2 Parte I – Distribuição Gama	1
2.1 Definição e parâmetros	1
2.2 Medidas de tendência central e dispersão	2
2.3 Probabilidades selecionadas	2
2.4 Relação com a Exponencial	2
2.5 Função de densidade (PDF)	3
2.6 Função acumulada (CDF)	3
2.7 Lei dos Grandes Números	4
2.8 Teorema do Limite Central	5
3 Parte II – Análise NHANES	7
3.1 Base de dados e variáveis selecionadas	7
3.2 Análise exploratória	7
3.2.1 Histograma do BMI	7
3.2.2 Boxplot do BMI	8
3.2.3 Boxplot do BMI por género	8
3.2.4 Dispersão entre BMI e BPSysAve	9
3.2.5 Medidas descritivas	9
3.3 Intervalo de confiança para a média do BMI	10
3.4 Visualização interativa	10
4 Conclusão	11

Lista de Figuras

1	Função de densidade da distribuição Gama para diferentes valores de α , com $\beta = 1$ fixo	3
2	Função acumulada da distribuição Gama para diferentes valores de α , com $\beta = 1$ fixo	3
3	Ilustração da LGN para a distribuição Gama($n = 1000$, $\alpha = 2$, $\beta = 1$) . .	4
4	Ilustração da LGN para a distribuição Gama($n = 5000$, $\alpha = 2$, $\beta = 1$) . .	4
5	Ilustração do TLC com distribuição Gama($N = 1000$, $n = 30$, $\alpha = 2$, $\beta = 1$)	5
6	Ilustração do TLC com distribuição Gama($N = 3000$, $n = 30$, $\alpha = 2$, $\beta = 1$)	6
7	Histograma do BMI	7
8	Boxplot do BMI	8
9	Boxplot do BMI por género	8
10	Dispersão entre BMI e pressão arterial sistólica média	9
11	Página inicial da aplicação Streamlit – Parte I (Distribuição Gama). . . .	10
12	Componente NHANES da aplicação – Parte II (Análise NHANES). . . .	11

Lista de Tabelas

1	Medidas teóricas da Gama($\alpha = 2, \beta = 1$)	2
2	Probabilidades da Gama($\alpha = 2, \beta = 1$)	2
3	Variáveis selecionadas da base NHANES	7
4	Medidas descritivas das variáveis selecionadas	9

1 Introdução

O presente trabalho desenvolve-se em duas partes complementares. Na primeira parte estuda-se a distribuição Gama, abordando a sua definição, os seus parâmetros, algumas medidas teóricas, probabilidades selecionadas, representações gráficas e simulações ilustrativas. Na segunda parte realiza-se uma análise exploratória da base de dados NHANES, centrada sobretudo na variável BMI, recorrendo a medidas descritivas, representações gráficas e à construção de um intervalo de confiança para a média.

A escolha destes dois temas permite articular conteúdos teóricos de Probabilidade com técnicas de Estatística Descritiva e Inferência Estatística. Para além disso, inclui-se uma componente de visualização interativa, através de uma aplicação em *Streamlit*, com o objetivo de complementar a exploração dos dados de forma simples e intuitiva.

2 Parte I – Distribuição Gama

2.1 Definição e parâmetros

A distribuição Gama(α, β) é uma distribuição contínua definida para $x > 0$. Neste trabalho considera-se a parametrização em termos de *shape* e *rate*, em que:

- $\alpha > 0$ representa o parâmetro de forma, controlando o formato da distribuição;
- $\beta > 0$ representa o parâmetro de taxa, influenciando a escala inversa da distribuição.

A respetiva função de densidade é dada por:

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0$$

Para ilustrar as principais propriedades da distribuição, foi considerado o caso particular $\alpha = 2$ e $\beta = 1$.

2.2 Medidas de tendência central e dispersão

Para $\alpha = 2$ e $\beta = 1$, obtêm-se as seguintes medidas teóricas:

Tabela 1: Medidas teóricas da Gama($\alpha = 2, \beta = 1$)

Medida	Fórmula	Valor
Média	α/β	2.000
Variância	α/β^2	2.000
Desvio-padrão	$\sqrt{\alpha/\beta^2}$	1.414
Moda	$(\alpha - 1)/\beta$	1.000
Q1 (25%)	$qgamma(0.25, 2, 1)$	1.074
Mediana (50%)	$qgamma(0.50, 2, 1)$	1.678
Q3 (75%)	$qgamma(0.75, 2, 1)$	2.693

A média e a variância são ambas iguais a 2, o que traduz uma dispersão moderada em torno do centro da distribuição. Além disso, a moda é inferior à média e à mediana, compatível com uma distribuição assimétrica à direita.

2.3 Probabilidades selecionadas

As probabilidades seguintes foram calculadas com recurso às funções de distribuição do R:

Tabela 2: Probabilidades da Gama($\alpha = 2, \beta = 1$)

Evento	Cálculo em R	Valor
$P(X \leq 2)$	$pgamma(2, 2, 1)$	0.5940
$P(X > 3)$	$1 - pgamma(3, 2, 1)$	0.1991
$P(1 < X < 3)$	$pgamma(3, 2, 1) - pgamma(1, 2, 1)$	0.4422

Verifica-se que cerca de 59,4% da probabilidade acumulada se encontra até ao valor 2, enquanto a probabilidade de observar valores superiores a 3 é aproximadamente 19,9%.

2.4 Relação com a Exponencial

Quando $\alpha = 1$, a distribuição Gama coincide com a distribuição Exponencial(β). Deste modo, a distribuição Exponencial pode ser vista como um caso particular da distribuição Gama.

2.5 Função de densidade (PDF)




Figura 1: Função de densidade da distribuição Gama para diferentes valores de α , com $\beta = 1$ fixo

Na Figura 1, fixou-se $\beta = 1$ e variou-se α . Para $\alpha = 1$ a curva é estritamente decrescente, enquanto para valores mais elevados surge um pico mais acentuado deslocado para a direita.

2.6 Função acumulada (CDF)




Figura 2: Função acumulada da distribuição Gama para diferentes valores de α , com $\beta = 1$ fixo

Na Figura 2, a função é crescente e tende para 1. Para valores mais elevados de α , a acumulação de probabilidade ocorre mais lentamente. A curva começa em $(0, 0)$, uma vez que a variável Gama apenas admite valores positivos.

2.7 Lei dos Grandes Números



Figura 3: Ilustração da LGN para a distribuição Gama($n = 1000$, $\alpha = 2$, $\beta = 1$)



Figura 4: Ilustração da LGN para a distribuição Gama($n = 5000$, $\alpha = 2$, $\beta = 1$)

Nas Figuras 3 e 4 foi calculada a média acumulada e comparada com a média teórica $\mu = \alpha/\beta = 2$. À medida que n aumenta, a média tende a estabilizar em torno do valor teórico, com menores oscilações para $n = 5000$, ilustrando o princípio da Lei dos Grandes Números.

2.8 Teorema do Limite Central

O Teorema do Limite Central afirma que, para amostras de dimensão suficientemente grande, a distribuição das médias amostrais tende para uma distribuição Normal, independentemente da distribuição original.



Figura 5: Ilustração do TLC com distribuição Gama($N = 1000$, $n = 30$, $\alpha = 2$, $\beta = 1$)



Figura 6: Ilustração do TLC com distribuição Gama($N = 3000$, $n = 30$, $\alpha = 2$, $\beta = 1$)

Considerando $\alpha = 2$, $\beta = 1$ e $n = 30$, o desvio-padrão teórico das médias amostrais é:

$$\frac{\sigma}{\sqrt{n}} = \frac{\sqrt{\alpha/\beta^2}}{\sqrt{n}} = \frac{\sqrt{2}}{\sqrt{30}} \approx 0.258$$

Para $N = 1000$ já existe uma aproximação visível à distribuição Normal. Para $N = 3000$ a distribuição torna-se mais suave e aproxima-se ainda mais da curva Normal teórica, evidenciando o comportamento previsto pelo Teorema do Limite Central.

3 Parte II – Análise NHANES

3.1 Base de dados e variáveis selecionadas

A base de dados NHANES (*National Health and Nutrition Examination Survey*), disponível no *package* NHANES do R [2], contém 10 000 observações e 76 variáveis. Após remoção de valores em falta, a base de trabalho ficou com 8 487 observações e 5 variáveis (4 270 do género feminino e 4 217 do masculino).

Tabela 3: Variáveis selecionadas da base NHANES

Variável	Tipo	Unidade	Descrição
Weight	Quantitativa contínua	kg	Peso corporal
Height	Quantitativa contínua	cm	Altura
BMI	Quantitativa contínua	kg/m ²	Índice de Massa Corporal
BPSysAve	Quantitativa contínua	mmHg	Pressão arterial sistólica média
Gender	Qualitativa nominal	—	Género

3.2 Análise exploratória

3.2.1 Histograma do BMI




Figura 7: Histograma do BMI

O histograma, apresentado na Figura 7, revela uma distribuição unimodal e ligeiramente assimétrica à direita. A maior concentração de observações encontra-se entre 20 e 30 kg/m², com uma cauda à direita compatível com a presença de valores extremos.

3.2.2 Boxplot do BMI




Figura 8: Boxplot do BMI

O boxplot, na Figura 8, mostra que a maioria das observações se concentra entre 22.76 e 31.40, com mediana de 26.65. Verifica-se a presença de vários *outliers* superiores, prolongando-se até 81.25, o que contribui para a assimetria à direita.

3.2.3 Boxplot do BMI por gênero




Figura 9: Boxplot do BMI por gênero

As medianas são de 27.05 (masculino) e 26.20 (feminino), conforme Figura 9. A distribuição feminina apresenta maior dispersão nos valores extremos, alcançando um máximo de 81.25 face a 63.91 no grupo masculino.

3.2.4 Dispersão entre BMI e BPSysAve




Figura 10: Dispersão entre BMI e pressão arterial sistólica média

O coeficiente de correlação de Pearson obtido foi de $r \approx 0.31$, indicando uma associação positiva fraca a moderada entre o BMI e a pressão arterial sistólica. A elevada dispersão dos pontos na Figura 10 evidencia que a relação não é perfeitamente linear, não sendo possível inferir qualquer relação causal.

3.2.5 Medidas descritivas

Tabela 4: Medidas descritivas das variáveis selecionadas

Variável	Média	Desvio-padrão	Mínimo	Máximo	Amplitude
Weight	77.86	23.37	17.10	230.70	213.60
Height	166.94	11.92	112.50	200.40	87.90
BMI	27.62	7.00	12.89	81.25	68.36
BPSysAve	118.13	17.20	76.00	226.00	150.00

A variável **Weight** apresenta a maior dispersão absoluta (amplitude de 213.60), enquanto **Height** é a mais concentrada. O BMI apresenta valor máximo de 81.25, evidenciando a existência de observações extremas. A variável **BPSysAve** apresenta amplitude de 150 mmHg.

3.3 Intervalo de confiança para a média do BMI

O intervalo de confiança de 95% para a média do BMI foi obtido com a função `t.test()` do R. Considerando o tamanho amostral elevado, a expressão utilizada é equivalente a:

$$IC_{95\%} = \bar{x} \pm 1.96 \cdot \frac{s}{\sqrt{n}}$$

A média amostral obtida foi de 27.62 kg/m² e o intervalo de confiança de 95% é:

$$IC_{95\%} = [27.47, 27.76]$$

A reduzida largura do intervalo sugere uma estimativa bastante precisa, consistente com a dimensão elevada da amostra ($n = 8\,487$).

3.4 Visualização interativa

Para complementar o trabalho, foi criada uma aplicação em *Streamlit* [3], disponível em:

<https://distribuicao-gama-nhanes-pulfvpycufjlaeqgwo3d6c.streamlit.app/>



Figura 11: Página inicial da aplicação Streamlit – Parte I (Distribuição Gama).



Figura 12: Componente NHANES da aplicação – Parte II (Análise NHANES).

4 Conclusão

Neste trabalho foi possível estudar a distribuição Gama sob diferentes perspetivas, incluindo a sua definição, parâmetros, medidas teóricas e representações gráficas. As simulações ilustraram a Lei dos Grandes Números e o Teorema do Limite Central.

Relativamente à base NHANES, a análise centrou-se no BMI, identificando assimetria à direita, comparando géneros e quantificando uma associação positiva moderada com a pressão arterial sistólica ($r \approx 0.31$). O intervalo de confiança para a média do BMI mostrou-se bastante preciso, refletindo a dimensão elevada da amostra.

A aplicação em *Streamlit* constituiu um complemento útil, articulando conteúdos teóricos, análise estatística e visualização de dados de acordo com os objetivos propostos.

Referências

- [1] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. Disponível em: <https://www.r-project.org/>. Acesso em: 16 maio 2026.
- [2] CRAN. *NHANES: Data from the US National Health and Nutrition Examination Survey*. Disponível em: <https://cran.r-project.org/package=NHANES>. Acesso em: 16 maio 2026.
- [3] Streamlit. *Deploy your app on Community Cloud*. Disponível em: <https://docs.streamlit.io/deploy/streamlit-community-cloud/deploy-your-app/deploy>. Acesso em: 16 maio 2026.
- [4] Streamlit. *Share your app*. Disponível em: <https://docs.streamlit.io/deploy/streamlit-community-cloud/share-your-app>. Acesso em: 16 maio 2026.
- [5] Azevedo, Joana Raquel; Gonçalves, Luís Filipe. *Distribuição Gama e NHANES – aplicação interativa em Streamlit*. Disponível em: <https://distribuicao-gama-nhanes-pulfvpycufjlaeqgwo3d6c.streamlit.app/>. Acesso em: 16 maio 2026.